UNIVERSIDADE PRESBITERIANA MACKENZIE

CAINÃ FERNANDES GUIMARÃES DA SILVA
GABRIEL DE OLIVEIRA MELONI
HUMBERTO GUTTAU BRAVO
JIMMY PAIVA GOMES

SISTEMA DE RECOMENDAÇÃO DE MEDICAMENTOS BASEADO EM DADOS DO UCI DRUG REVIEW: UMA ABORDAGEM COM TÉCNICAS DE ANÁLISE DE DADOS E AGRUPAMENTO

São Paulo
2025

CAINÃ FERNANDES GUIMARÃES DA SILVA
GABRIEL DE OLIVEIRA MELONI
HUMBERTO GUTTAU BRAVO
JIMMY PAIVA GOMES

SISTEMA DE RECOMENDAÇÃO DE MEDICAMENTOS BASEADO EM DADOS DO UCI DRUG REVIEW: UMA ABORDAGEM COM TÉCNICAS DE ANÁLISE DE DADOS E AGRUPAMENTO

Trabalho de projeto prático apresentado ao curso de ciência de dados da Universidade Presbiteriana Mackenzie, como requisito parcial da matéria de projeto aplicado III

São Paulo
2026

LISTA DE TABELAS

LISTA DE ILUSTRAÇÕES

Figura 1: Cronograma do projeto.....8

SUMÁRIO

1. INTRODUÇÃO..... 6
1.1. CONTEXTO DO TRABALHO..... 6
1.2. MOTIVAÇÃO DO PROJETO.....7
1.3. JUSTIFICATIVA.....7
1.4. OBJETIVOS GERAIS E ESPECÍFICOS.....8
1.5. CRONOGRAMA.....9
1.6. REPOSITÓRIO DO PROJETO..... 9
2. REFERENCIAL TEÓRICO.....10
CONCLUSÃO.....14
REFERÊNCIAS.....15

1. INTRODUÇÃO

O avanço das tecnologias da informação e comunicação, aliado ao crescimento exponencial na geração e disponibilidade de dados, tem impulsionado o desenvolvimento de sistemas inteligentes voltados ao apoio à tomada de decisão em diversos setores, especialmente na área da saúde. Dentre essas soluções, destacam-se os sistemas de recomendação, que utilizam dados e algoritmos para fornecer sugestões personalizadas aos usuários, contribuindo para a melhoria da experiência e da assertividade nas escolhas (RICCI; ROKACH; SHAPIRA, 2015).

No contexto farmacêutico, observa-se que as farmácias desempenham um papel fundamental como ponto de acesso primário aos cuidados de saúde. No entanto, a facilidade de acesso a medicamentos, aliada à falta de orientação adequada, contribui para a prática recorrente da automedicação, frequentemente realizada de forma inadequada. De acordo com a Organização Mundial da Saúde, o uso irracional de medicamentos constitui um dos principais desafios globais em saúde pública, podendo ocasionar reações adversas, interações medicamentosas e agravamento de condições clínicas (OMS, 2002).

Diante desse cenário, surge a seguinte problemática: de que forma um sistema de recomendação pode auxiliar clientes de farmácia na escolha adequada de medicamentos, considerando sintomas apresentados e boas práticas farmacológicas? Parte-se da hipótese de que a aplicação de um sistema estruturado de recomendação, baseado em dados e diretrizes da área da saúde, pode contribuir significativamente para a promoção do uso racional de medicamentos, além de ampliar o acesso à informação de qualidade.

Adicionalmente, o presente projeto apresenta caráter extensionista, ao propor uma solução tecnológica voltada à resolução de uma demanda social relevante, relacionada ao acesso à informação em saúde. Nesse sentido, a pesquisa alinha-se aos Objetivos de Desenvolvimento Sustentável da Organização das Nações Unidas, especialmente ao ODS 3 — Saúde e Bem-Estar, que visa assegurar uma vida saudável e promover o bem-estar para todos, em todas as idades (ONU, 2015).

1.1. CONTEXTO DO TRABALHO

O presente estudo insere-se no contexto da transformação digital aplicada ao setor de saúde, com foco específico no ambiente farmacêutico, no qual se observa uma crescente demanda por soluções tecnológicas capazes de melhorar a qualidade do atendimento e a segurança dos usuários.

As farmácias, muitas vezes, constituem o primeiro ponto de contato da população com serviços de saúde, sobretudo em situações de baixa complexidade. Nesse ambiente, é comum que clientes busquem orientação para tratar sintomas diversos, frequentemente sem acompanhamento médico. Contudo, a ausência de suporte adequado pode levar à escolha incorreta de medicamentos.

Nesse cenário, os sistemas de recomendação apresentam-se como uma alternativa promissora, uma vez que permitem a análise de dados e a geração de sugestões personalizadas. Esses sistemas têm sido amplamente utilizados em setores como comércio eletrônico e serviços digitais, sendo adaptáveis ao contexto da saúde, desde que respeitadas as particularidades e limitações do domínio farmacêutico (AGGARWAL, 2016).

1.2. MOTIVAÇÃO DO PROJETO

A motivação para o desenvolvimento deste projeto está fundamentada na necessidade de mitigar os riscos associados à automedicação inadequada, prática amplamente disseminada na sociedade contemporânea. A dificuldade de interpretação de informações técnicas, aliada à ausência de orientação profissional em determinados contextos, contribui para decisões equivocadas por parte dos usuários.

Além disso, observa-se uma lacuna significativa entre a disponibilidade de informações sobre medicamentos e a capacidade dos indivíduos de utilizá-las de forma correta e segura. Nesse sentido, a utilização de tecnologias baseadas em dados surge como uma alternativa viável para reduzir essa lacuna, tornando a informação mais acessível, estruturada e aplicável.

Ademais, o desenvolvimento deste projeto também se justifica pelo potencial de aplicação prática dos conhecimentos adquiridos na área de ciência de dados e sistemas inteligentes, permitindo a construção de uma solução com impacto social relevante.

1.3. JUSTIFICATIVA

A relevância deste projeto pode ser compreendida sob três perspectivas principais: social, acadêmica e tecnológica.

Sob a perspectiva social, a proposta contribui diretamente para a promoção do uso racional de medicamentos, auxiliando na redução de riscos associados à automedicação inadequada. Ao oferecer recomendações baseadas em critérios estruturados, o sistema pode atuar como ferramenta de apoio à decisão, promovendo maior segurança e autonomia ao usuário.

No âmbito acadêmico, o projeto possibilita a integração de conceitos teóricos e práticos relacionados à ciência de dados, sistemas de recomendação e desenvolvimento de soluções aplicadas à saúde, contribuindo para a formação de profissionais capacitados para lidar com problemas complexos e multidisciplinares.

Do ponto de vista tecnológico, a proposta amplia as possibilidades de aplicação de sistemas de recomendação em áreas sensíveis, como a saúde, incentivando o desenvolvimento de soluções inovadoras que considerem aspectos éticos, técnicos e sociais.

Além disso, destaca-se o caráter extensionista do projeto, uma vez que a solução proposta busca atender uma necessidade concreta da sociedade, contribuindo para o alcance dos Objetivos de Desenvolvimento Sustentável, em especial o ODS 3 — Saúde e Bem-Estar, ao promover o acesso à informação de qualidade e práticas mais seguras no uso de medicamentos.

1.4. OBJETIVOS GERAIS E ESPECÍFICOS

O presente trabalho tem como objetivo desenvolver um sistema de recomendação de medicamentos que, a partir das doenças ou sintomas informados pelos usuários, seja capaz de gerar sugestões fundamentadas em dados históricos de avaliações disponíveis no conjunto UCI ML Drug Review. Para tanto, a proposta baseia-se na análise de informações como a condição clínica relatada, os medicamentos associados e as respectivas avaliações atribuídas pelos usuários, permitindo a identificação de padrões de relevância e similaridade entre diferentes perfis e contextos de uso.

Nesse sentido, o sistema será concebido de modo a explorar técnicas de recomendação baseadas em dados, visando estruturar um modelo capaz de correlacionar

doenças a medicamentos potencialmente adequados, a partir de evidências empíricas extraídas das experiências reportadas pelos próprios usuários. Adicionalmente, pretende-se incorporar critérios de consistência e qualidade das avaliações, de forma a aprimorar a confiabilidade das recomendações geradas.

Destaca-se que a solução proposta não tem como finalidade substituir a orientação de profissionais da saúde, mas sim atuar como instrumento complementar de apoio à tomada de decisão, contribuindo para a ampliação do acesso à informação e para a promoção do uso mais consciente de medicamentos. Dessa forma, o projeto também se alinha aos princípios do Objetivo de Desenvolvimento Sustentável 3 — Saúde e Bem-Estar, ao buscar fomentar práticas que favoreçam a qualidade de vida e o bem-estar da população.

1.5. CRONOGRAMA

Figura 1: Cronograma do projeto

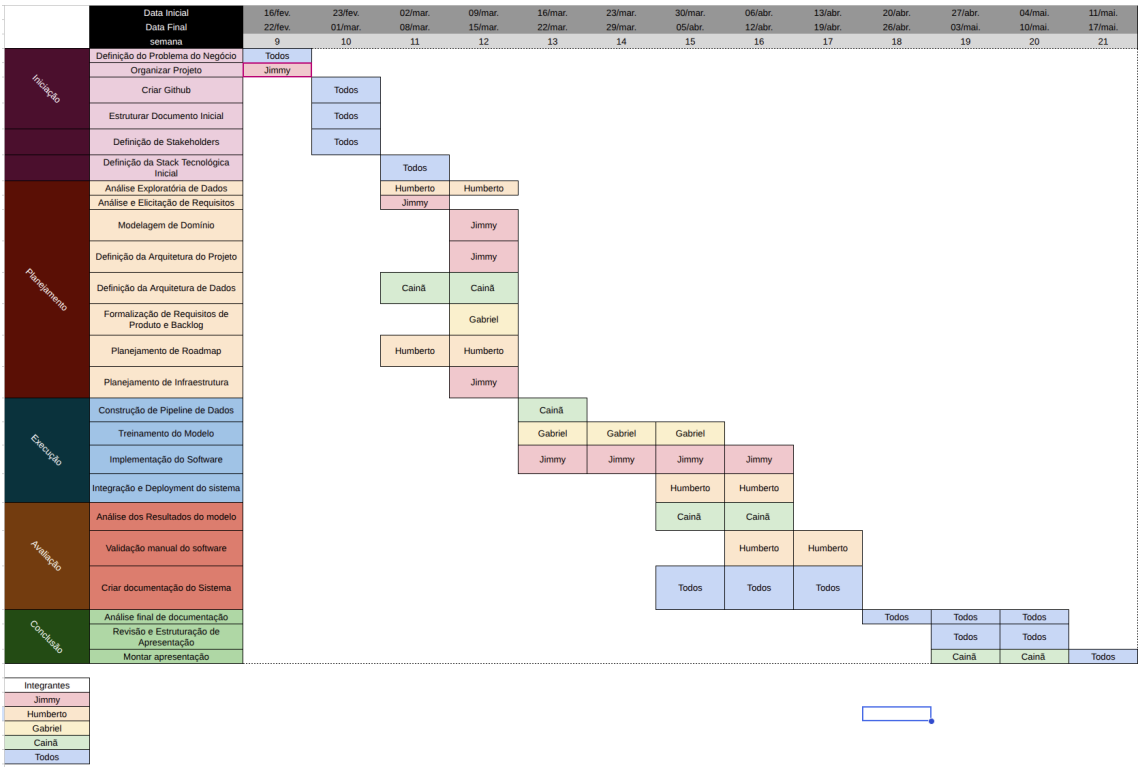

Fonte: Autoral

1.6. REPOSITÓRIO DO PROJETO

Para o projeto, foi disponibilizado o seguinte repositório no github: Repositório

2. REFERENCIAL TEÓRICO

Os sistemas de recomendação têm se consolidado como ferramentas fundamentais no contexto da análise de dados, sendo amplamente utilizados para auxiliar usuários na tomada de decisão em diferentes domínios, como comércio eletrônico, plataformas de streaming e serviços digitais. Esses sistemas têm como principal objetivo oferecer sugestões personalizadas a partir da análise de grandes volumes de dados, considerando preferências, comportamentos e padrões históricos dos usuários (RICCI; ROKACH; SHAPIRA, 2015). Ao reduzir a sobrecarga informacional e aumentar a relevância das recomendações, tais sistemas contribuem diretamente para a melhoria da experiência do usuário e para a eficiência dos processos decisórios.

A estruturação de sistemas de recomendação pode ocorrer por meio de diferentes abordagens metodológicas. A filtragem colaborativa, uma das mais tradicionais, baseia-se na ideia de que usuários com comportamentos semelhantes tendem a compartilhar preferências. Dessa forma, recomendações são geradas a partir da análise de interações entre usuários e itens, permitindo inferir novas preferências com base em padrões coletivos (SARWAR et al., 2001). Por outro lado, a filtragem baseada em conteúdo utiliza características específicas dos itens para recomendar alternativas semelhantes às já consumidas pelo usuário, sendo especialmente útil em contextos com menor volume de dados históricos (AGGARWAL, 2016).

Além dessas abordagens, modelos híbridos têm sido amplamente explorados com o objetivo de superar limitações individuais, como o problema de inicialização a frio (*cold start*) e a esparsidade de dados. Conforme destacado por BURKE (2002), a combinação de diferentes técnicas permite aumentar a robustez dos sistemas de recomendação, proporcionando melhores resultados em cenários complexos e heterogêneos.

No contexto da saúde, a aplicação de sistemas de recomendação apresenta desafios adicionais, uma vez que envolve dados sensíveis e decisões que podem impactar diretamente a qualidade de vida dos indivíduos. Ainda assim, o uso dessas tecnologias tem crescido significativamente, especialmente como ferramentas de apoio à decisão. De acordo com SHICKEL et al. (2017), a incorporação de técnicas de aprendizado de máquina na área da saúde possibilita o desenvolvimento de soluções capazes de analisar grandes volumes de dados e fornecer informações relevantes para usuários e profissionais.

Nesse cenário, destaca-se a importância da utilização responsável dessas tecnologias, considerando aspectos como segurança, confiabilidade e transparência. Sistemas de recomendação aplicados à saúde não devem substituir a atuação de profissionais qualificados, mas sim atuar como instrumentos complementares que auxiliem na interpretação de informações e na tomada de decisões mais informadas.

A crescente digitalização dos serviços e o aumento da participação dos usuários na geração de conteúdo têm contribuído para a formação de bases de dados ricas e diversificadas. O conjunto de dados UCI ML Drug Review insere-se nesse contexto, reunindo informações sobre doenças, medicamentos, avaliações numéricas e comentários textuais fornecidos por usuários. Esse tipo de dataset permite explorar relações entre condições clínicas e tratamentos a partir de experiências reais, possibilitando a construção de modelos baseados em evidências empíricas.

A utilização de dados provenientes de avaliações de usuários apresenta vantagens e limitações. Por um lado, tais dados refletem a experiência prática dos indivíduos, incluindo percepções sobre eficácia, efeitos colaterais e satisfação com o tratamento. Por outro lado, essas informações possuem natureza subjetiva e podem ser influenciadas por fatores individuais, o que exige cautela na interpretação dos resultados (DREW; KELLOGG; LEE, 2020). Dessa forma, é fundamental compreender que tais sistemas fornecem suporte informacional, não substituindo evidências clínicas.

Além das informações estruturadas, como notas e categorias, o dataset também inclui dados textuais que podem ser explorados por meio de técnicas de processamento de linguagem natural (Natural Language Processing — NLP). Essas técnicas permitem analisar grandes volumes de texto não estruturado, identificando padrões semânticos, sentimentos e tópicos relevantes. Segundo MINER et al. (2012), a utilização de NLP amplia significativamente a capacidade analítica dos sistemas de recomendação, tornando-os mais sensíveis ao contexto e às nuances das avaliações.

Técnicas como vetorização de texto, incluindo métodos como TF-IDF, possibilitam a transformação de dados textuais em representações numéricas, permitindo sua utilização em modelos computacionais. De acordo com MANNING, RAGHAVAN e SCHÜTZE (2008), essas abordagens são fundamentais para a análise de informações textuais em larga escala, sendo amplamente utilizadas em sistemas de recuperação de informação e aprendizado de máquina.

Outro componente relevante na análise de dados é a utilização de técnicas de aprendizado não supervisionado, especialmente algoritmos de agrupamento (*clustering*).

Esses métodos permitem identificar estruturas ocultas nos dados, agrupando elementos com características semelhantes sem a necessidade de rótulos previamente definidos (HAN; KAMBER; PEI, 2012). No contexto deste projeto, o uso de *clustering* pode contribuir para a identificação de padrões entre doenças, medicamentos e avaliações, possibilitando a segmentação de grupos com comportamentos semelhantes.

A qualidade dos agrupamentos gerados por algoritmos de *clustering* deve ser avaliada por meio de métricas adequadas. Nesse contexto, destaca-se o *Silhouette Score*, proposto por ROUSSEEUW (1987), que mede simultaneamente a coesão interna dos grupos e a separação entre clusters distintos. Essa métrica baseia-se na comparação entre a distância média de um elemento em relação aos demais elementos do mesmo grupo e a distância em relação ao grupo mais próximo.

Os valores do *Silhouette Score* variam entre -1 e 1, sendo que valores próximos de 1 indicam agrupamentos bem definidos, valores próximos de zero sugerem sobreposição entre grupos e valores negativos indicam possíveis erros na alocação dos elementos. Conforme discutido por TAN, STEINBACH e KUMAR (2005), essa métrica é amplamente utilizada para validar modelos de agrupamento e auxiliar na determinação do número ideal de clusters.

No contexto deste projeto, a utilização do *Silhouette Score* é fundamental para garantir a qualidade dos agrupamentos utilizados no sistema de recomendação. A identificação de clusters bem definidos permite estruturar recomendações mais consistentes, baseadas em padrões reais observados nos dados, contribuindo para a robustez do modelo proposto.

Além da construção e validação dos modelos, é importante considerar as métricas de avaliação utilizadas em sistemas de recomendação. Indicadores como precisão, recall e erro médio quadrático (RMSE) são amplamente empregados para medir o desempenho dos modelos, permitindo avaliar sua capacidade de prever preferências e gerar recomendações relevantes (HERLOCKER et al., 2004). A escolha adequada dessas métricas é essencial para garantir a confiabilidade dos resultados.

Do ponto de vista social, o desenvolvimento de sistemas baseados em dados na área da saúde está alinhado a iniciativas globais voltadas à melhoria da qualidade de vida da população. Os Objetivos de Desenvolvimento Sustentável propostos pela Organização das Nações Unidas destacam a importância de promover o acesso à saúde e ao bem-estar por meio de soluções inovadoras e acessíveis (ONU, 2015).

Nesse mesmo sentido, a Organização Mundial da Saúde enfatiza a necessidade de promover o uso racional de medicamentos, destacando que decisões informadas são fundamentais para evitar riscos e garantir tratamentos eficazes (OMS, 2002). A utilização de sistemas de recomendação pode contribuir para esse objetivo ao ampliar o acesso à informação de qualidade.

Adicionalmente, questões éticas relacionadas ao uso de dados devem ser consideradas no desenvolvimento de sistemas inteligentes. Aspectos como privacidade, transparência e responsabilidade são fundamentais para garantir a confiança dos usuários. Conforme discutido por FLORIDI et al. (2018), o desenvolvimento de sistemas baseados em inteligência artificial deve seguir princípios éticos que assegurem a proteção dos indivíduos e a utilização responsável das tecnologias.

Dessa forma, a integração entre sistemas de recomendação, técnicas de processamento de linguagem natural, métodos de agrupamento e métricas de validação, como o *Silhouette Score*, constitui uma abordagem robusta e coerente com os objetivos deste projeto. A utilização do dataset UCI ML Drug Review, aliada a essas técnicas, possibilita o desenvolvimento de uma solução capaz de apoiar a tomada de decisão dos usuários, promovendo o acesso à informação e contribuindo para o uso mais consciente de medicamentos.

CONCLUSÃO

REFERÊNCIAS

AGGARWAL, Charu C. *Recommender Systems: The Textbook*. Cham: Springer, 2016.

BURKE, Robin. Hybrid recommender systems: Survey and experiments. *User Modeling and User-Adapted Interaction*, v. 12, n. 4, p. 331–370, 2002.

DREW, Daniel A.; KELLOGG, Megan D.; LEE, Hyun J. Machine learning in medicine: A practical introduction. *New England Journal of Medicine*, 2020.

FLORIDI, Luciano et al. AI4People—An ethical framework for a good AI society. *Minds and Machines*, v. 28, p. 689–707, 2018.

HAN, Jiawei; KAMBER, Micheline; PEI, Jian. *Data Mining: Concepts and Techniques*. 3. ed. Waltham: Morgan Kaufmann, 2012.

HARPER, F. Maxwell; KONSTAN, Joseph A. The MovieLens datasets: History and context. *ACM Transactions on Interactive Intelligent Systems*, v. 5, n. 4, 2016.

HERLOCKER, Jonathan L. et al. Evaluating collaborative filtering recommender systems. *ACM Transactions on Information Systems*, v. 22, n. 1, 2004.

JESSICA LI. KUC Hackathon Winter 2018 – Drug Review Dataset. Kaggle, 2018.

MANNING, Christopher D.; RAGHAVAN, Prabhakar; SCHÜTZE, Hinrich. *Introduction to Information Retrieval*. Cambridge: Cambridge University Press, 2008.

MINER, Gary et al. *Practical Text Mining and Statistical Analysis for Non-structured Text Data Applications*. Academic Press, 2012.

ORGANIZAÇÃO DAS NAÇÕES UNIDAS (ONU). *Transformando nosso mundo: a Agenda 2030 para o Desenvolvimento Sustentável*. Nova York: ONU, 2015.

ORGANIZAÇÃO MUNDIAL DA SAÚDE (OMS). *Promoting rational use of medicines: core components*. Geneva: WHO, 2002.

RICCI, Francesco; ROKACH, Lior; SHAPIRA, Bracha. *Recommender Systems Handbook*. 2. ed. Boston: Springer, 2015.

ROUSSEEUW, Peter J. Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, v. 20, p. 53–65, 1987.

SARWAR, Badrul et al. Item-based collaborative filtering recommendation algorithms. In: *Proceedings of the 10th International World Wide Web Conference*. 2001.

SHICKEL, Benjamin et al. Deep learning in healthcare: A review. *Journal of Biomedical Informatics*, v. 75, p. 3–21, 2017.

TAN, Pang-Ning; STEINBACH, Michael; KUMAR, Vipin. *Introduction to Data Mining*. Boston: Pearson, 2005.