UNIVERSIDADE PRESBITERIANA MACKENZIE

CAINÃ FERNANDES GUIMARÃES DA SILVA
GABRIEL DE OLIVEIRA MELONI
HUMBERTO GUTTAU BRAVO
JIMMY PAIVA GOMES

SISTEMA DE RECOMENDAÇÃO DE MEDICAMENTOS BASEADO EM DADOS DO UCI DRUG REVIEW: UMA ABORDAGEM COM TÉCNICAS DE ANÁLISE DE DADOS E AGRUPAMENTO

São Paulo
2026

CAINÃ FERNANDES GUIMARÃES DA SILVA
GABRIEL DE OLIVEIRA MELONI
HUMBERTO GUTTAU BRAVO
JIMMY PAIVA GOMES

SISTEMA DE RECOMENDAÇÃO DE MEDICAMENTOS BASEADO EM DADOS DO UCI DRUG REVIEW: UMA ABORDAGEM COM TÉCNICAS DE ANÁLISE DE DADOS E AGRUPAMENTO

Trabalho de projeto prático apresentado ao curso de ciência de dados da Universidade Presbiteriana Mackenzie, como requisito parcial da matéria de projeto aplicado III

São Paulo
2026

LISTA DE TABELAS

LISTA DE ILUSTRAÇÕES

Figura 1: Cronograma do projeto.....9
Figura 2: Fluxo metodológico do projeto.....14

SUMÁRIO

1. INTRODUÇÃO..... 6
1.1. CONTEXTO DO TRABALHO..... 6
1.2. MOTIVAÇÃO DO PROJETO.....7
1.3. JUSTIFICATIVA.....7
1.4. OBJETIVOS GERAIS E ESPECÍFICOS.....8
1.5. CRONOGRAMA.....9
1.6. REPOSITÓRIO DO PROJETO..... 9
2. REFERENCIAL TEÓRICO.....10
3. METODOLOGIA.....13
3.1. DEFINIÇÃO DO PROBLEMA E OBJETIVOS..... 14
3.2. COLETA DE DADOS..... 15
3.3. PRÉ-PROCESSAMENTO E LIMPEZA DOS DADOS..... 16
3.4. DIVISÃO E ESTRUTURAÇÃO DOS DADOS.....16
3.5. SELEÇÃO E IMPLEMENTAÇÃO DO ALGORITMO..... 17
3.6. SELEÇÃO E IMPLEMENTAÇÃO DO ALGORITMO..... 17
3.7. AVALIAÇÃO DO DESEMPENHO..... 18
3.8. OTIMIZAÇÃO E AJUSTES..... 19
3.9. IMPLANTAÇÃO E MONITORAMENTO.....20
CONCLUSÃO.....21
REFERÊNCIAS..... 22

1. INTRODUÇÃO

O avanço das tecnologias da informação e comunicação, aliado ao crescimento exponencial na geração e disponibilidade de dados, tem impulsionado o desenvolvimento de sistemas inteligentes voltados ao apoio à tomada de decisão em diversos setores, especialmente na área da saúde. Dentre essas soluções, destacam-se os sistemas de recomendação, que utilizam dados e algoritmos para fornecer sugestões personalizadas aos usuários, contribuindo para a melhoria da experiência e da assertividade nas escolhas (RICCI; ROKACH; SHAPIRA, 2015).

No contexto farmacêutico, observa-se que as farmácias desempenham um papel fundamental como ponto de acesso primário aos cuidados de saúde. No entanto, a facilidade de acesso a medicamentos, aliada à falta de orientação adequada, contribui para a prática recorrente da automedicação, frequentemente realizada de forma inadequada. De acordo com a Organização Mundial da Saúde, o uso irracional de medicamentos constitui um dos principais desafios globais em saúde pública, podendo ocasionar reações adversas, interações medicamentosas e agravamento de condições clínicas (OMS, 2002).

Diante desse cenário, surge a seguinte problemática: de que forma um sistema de recomendação pode auxiliar clientes de farmácia na escolha adequada de medicamentos, considerando sintomas apresentados e boas práticas farmacológicas? Parte-se da hipótese de que a aplicação de um sistema estruturado de recomendação, baseado em dados e diretrizes da área da saúde, pode contribuir significativamente para a promoção do uso racional de medicamentos, além de ampliar o acesso à informação de qualidade.

Adicionalmente, o presente projeto apresenta caráter extensionista, ao propor uma solução tecnológica voltada à resolução de uma demanda social relevante, relacionada ao acesso à informação em saúde. Nesse sentido, a pesquisa alinha-se aos Objetivos de Desenvolvimento Sustentável da Organização das Nações Unidas, especialmente ao ODS 3 — Saúde e Bem-Estar, que visa assegurar uma vida saudável e promover o bem-estar para todos, em todas as idades (ONU, 2015).

1.1. CONTEXTO DO TRABALHO

O presente estudo insere-se no contexto da transformação digital aplicada ao setor de saúde, com foco específico no ambiente farmacêutico, no qual se observa uma

crescente demanda por soluções tecnológicas capazes de melhorar a qualidade do atendimento e a segurança dos usuários.

As farmácias, muitas vezes, constituem o primeiro ponto de contato da população com serviços de saúde, sobretudo em situações de baixa complexidade. Nesse ambiente, é comum que clientes busquem orientação para tratar sintomas diversos, frequentemente sem acompanhamento médico. Contudo, a ausência de suporte adequado pode levar à escolha incorreta de medicamentos.

Nesse cenário, os sistemas de recomendação apresentam-se como uma alternativa promissora, uma vez que permitem a análise de dados e a geração de sugestões personalizadas. Esses sistemas têm sido amplamente utilizados em setores como comércio eletrônico e serviços digitais, sendo adaptáveis ao contexto da saúde, desde que respeitadas as particularidades e limitações do domínio farmacêutico (AGGARWAL, 2016).

1.2. MOTIVAÇÃO DO PROJETO

A motivação para o desenvolvimento deste projeto está fundamentada na necessidade de mitigar os riscos associados à automedicação inadequada, prática amplamente disseminada na sociedade contemporânea. A dificuldade de interpretação de informações técnicas, aliada à ausência de orientação profissional em determinados contextos, contribui para decisões equivocadas por parte dos usuários.

Além disso, observa-se uma lacuna significativa entre a disponibilidade de informações sobre medicamentos e a capacidade dos indivíduos de utilizá-las de forma correta e segura. Nesse sentido, a utilização de tecnologias baseadas em dados surge como uma alternativa viável para reduzir essa lacuna, tornando a informação mais acessível, estruturada e aplicável.

Ademais, o desenvolvimento deste projeto também se justifica pelo potencial de aplicação prática dos conhecimentos adquiridos na área de ciência de dados e sistemas inteligentes, permitindo a construção de uma solução com impacto social relevante.

1.3. JUSTIFICATIVA

A relevância deste projeto pode ser compreendida sob três perspectivas principais: social, acadêmica e tecnológica.

Sob a perspectiva social, a proposta contribui diretamente para a promoção do uso racional de medicamentos, auxiliando na redução de riscos associados à automedicação inadequada. Ao oferecer recomendações baseadas em critérios estruturados, o sistema pode atuar como ferramenta de apoio à decisão, promovendo maior segurança e autonomia ao usuário.

No âmbito acadêmico, o projeto possibilita a integração de conceitos teóricos e práticos relacionados à ciência de dados, sistemas de recomendação e desenvolvimento de soluções aplicadas à saúde, contribuindo para a formação de profissionais capacitados para lidar com problemas complexos e multidisciplinares.

Do ponto de vista tecnológico, a proposta amplia as possibilidades de aplicação de sistemas de recomendação em áreas sensíveis, como a saúde, incentivando o desenvolvimento de soluções inovadoras que considerem aspectos éticos, técnicos e sociais.

Além disso, destaca-se o caráter extensionista do projeto, uma vez que a solução proposta busca atender uma necessidade concreta da sociedade, contribuindo para o alcance dos Objetivos de Desenvolvimento Sustentável, em especial o ODS 3 — Saúde e Bem-Estar, ao promover o acesso à informação de qualidade e práticas mais seguras no uso de medicamentos.

1.4. OBJETIVOS GERAIS E ESPECÍFICOS

O presente trabalho tem como objetivo desenvolver um sistema de recomendação de medicamentos que, a partir do diagnóstico de doenças informado pelos usuários, seja capaz de gerar sugestões fundamentadas em dados históricos de avaliações disponíveis no conjunto UCI ML Drug Review. Para tanto, a proposta baseia-se na análise integrada de informações como a condição clínica relatada, os medicamentos associados e as respectivas avaliações atribuídas pelos usuários, permitindo a identificação de padrões de relevância, similaridade e aceitação entre diferentes contextos de uso.

Nesse sentido, o sistema será concebido de modo a explorar técnicas de análise de dados e sistemas de recomendação, visando estruturar um modelo capaz de correlacionar doenças a medicamentos potencialmente relevantes, a partir de evidências empíricas extraídas das experiências reportadas pelos próprios usuários. Adicionalmente, pretende-se incorporar critérios de consistência, frequência e qualidade

das avaliações, com o objetivo de aprimorar a confiabilidade das recomendações e possibilitar a identificação de medicamentos que apresentem maior potencial de priorização em processos de aquisição no contexto farmacêutico.

Destaca-se que a solução proposta não tem como finalidade substituir a orientação de profissionais da saúde, mas sim atuar como instrumento complementar de apoio à tomada de decisão, contribuindo para a ampliação do acesso à informação e para a promoção do uso mais consciente de medicamentos. Dessa forma, o projeto também se alinha aos princípios do Objetivo de Desenvolvimento Sustentável 3 — Saúde e Bem-Estar, ao buscar fomentar práticas que favoreçam a qualidade de vida e o bem-estar da população.

1.5. CRONOGRAMA

Figura 1: Cronograma do projeto

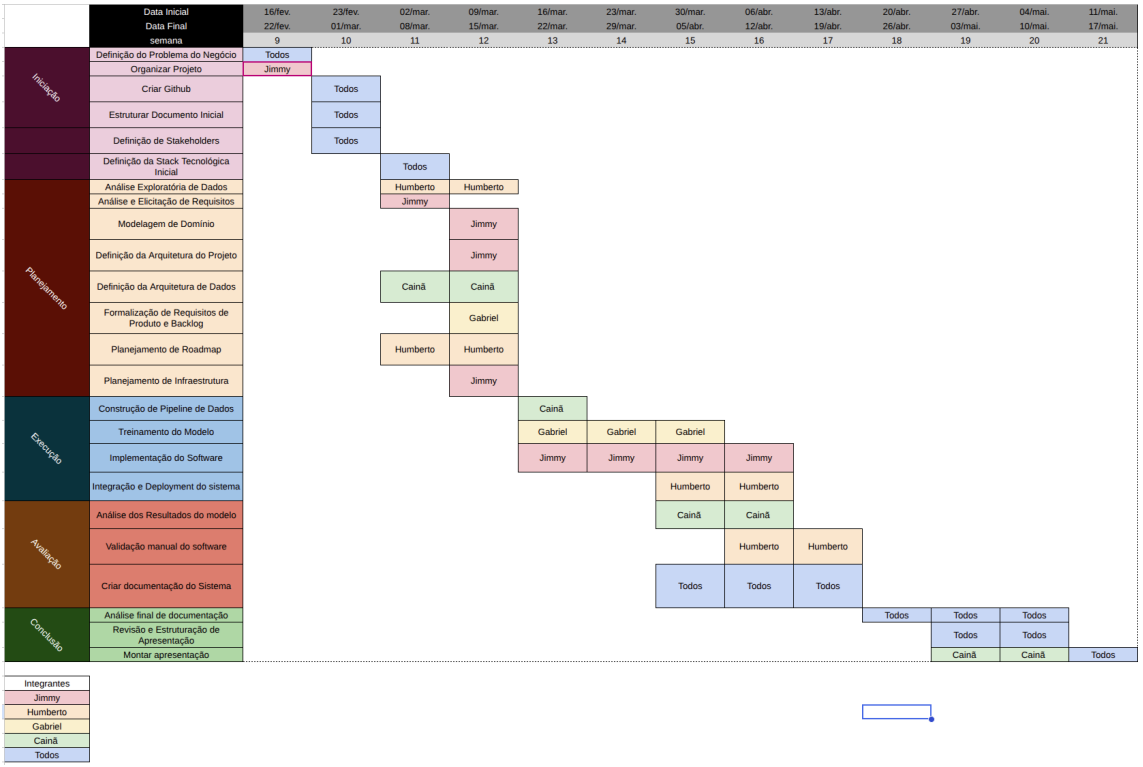

Fonte: Autoral

1.6. REPOSITÓRIO DO PROJETO

Para o projeto, foi disponibilizado o seguinte repositório no github: Repositório

2. REFERENCIAL TEÓRICO

Os sistemas de recomendação têm se consolidado como ferramentas fundamentais no contexto da análise de dados, sendo amplamente utilizados para auxiliar usuários na tomada de decisão em diferentes domínios, como comércio eletrônico, plataformas de streaming e serviços digitais. Esses sistemas têm como principal objetivo oferecer sugestões personalizadas a partir da análise de grandes volumes de dados, considerando preferências, comportamentos e padrões históricos dos usuários (RICCI; ROKACH; SHAPIRA, 2015). Ao reduzir a sobrecarga informacional e aumentar a relevância das recomendações, tais sistemas contribuem diretamente para a melhoria da experiência do usuário e para a eficiência dos processos decisórios.

A estruturação de sistemas de recomendação pode ocorrer por meio de diferentes abordagens metodológicas. A filtragem colaborativa, uma das mais tradicionais, baseia-se na ideia de que usuários com comportamentos semelhantes tendem a compartilhar preferências. Dessa forma, recomendações são geradas a partir da análise de interações entre usuários e itens, permitindo inferir novas preferências com base em padrões coletivos (SARWAR et al., 2001). Por outro lado, a filtragem baseada em conteúdo utiliza características específicas dos itens para recomendar alternativas semelhantes às já consumidas pelo usuário, sendo especialmente útil em contextos com menor volume de dados históricos (AGGARWAL, 2016).

Além dessas abordagens, modelos híbridos têm sido amplamente explorados com o objetivo de superar limitações individuais, como o problema de inicialização a frio (*cold start*) e a esparsidade de dados. Conforme destacado por BURKE (2002), a combinação de diferentes técnicas permite aumentar a robustez dos sistemas de recomendação, proporcionando melhores resultados em cenários complexos e heterogêneos.

No contexto da saúde, a aplicação de sistemas de recomendação apresenta desafios adicionais, uma vez que envolve dados sensíveis e decisões que podem impactar diretamente a qualidade de vida dos indivíduos. Ainda assim, o uso dessas tecnologias tem crescido significativamente, especialmente como ferramentas de apoio à decisão. De acordo com SHICKEL et al. (2017), a incorporação de técnicas de aprendizado de máquina na área da saúde possibilita o desenvolvimento de soluções capazes de analisar grandes volumes de dados e fornecer informações relevantes para usuários e profissionais.

Nesse cenário, destaca-se a importância da utilização responsável dessas tecnologias, considerando aspectos como segurança, confiabilidade e transparência. Sistemas de recomendação aplicados à saúde não devem substituir a atuação de profissionais qualificados, mas sim atuar como instrumentos complementares que auxiliem na interpretação de informações e na tomada de decisões mais informadas.

A crescente digitalização dos serviços e o aumento da participação dos usuários na geração de conteúdo têm contribuído para a formação de bases de dados ricas e diversificadas. O conjunto de dados UCI ML Drug Review insere-se nesse contexto, reunindo informações sobre doenças, medicamentos, avaliações numéricas e comentários textuais fornecidos por usuários. Esse tipo de dataset permite explorar relações entre condições clínicas e tratamentos a partir de experiências reais, possibilitando a construção de modelos baseados em evidências empíricas.

A utilização de dados provenientes de avaliações de usuários apresenta vantagens e limitações. Por um lado, tais dados refletem a experiência prática dos indivíduos, incluindo percepções sobre eficácia, efeitos colaterais e satisfação com o tratamento. Por outro lado, essas informações possuem natureza subjetiva e podem ser influenciadas por fatores individuais, o que exige cautela na interpretação dos resultados (DREW; KELLOGG; LEE, 2020). Dessa forma, é fundamental compreender que tais sistemas fornecem suporte informacional, não substituindo evidências clínicas.

Além das informações estruturadas, como notas e categorias, o dataset também inclui dados textuais que podem ser explorados por meio de técnicas de processamento de linguagem natural (Natural Language Processing — NLP). Essas técnicas permitem analisar grandes volumes de texto não estruturado, identificando padrões semânticos, sentimentos e tópicos relevantes. Segundo MINER et al. (2012), a utilização de NLP amplia significativamente a capacidade analítica dos sistemas de recomendação, tornando-os mais sensíveis ao contexto e às nuances das avaliações.

Técnicas como vetorização de texto, incluindo métodos como TF-IDF, possibilitam a transformação de dados textuais em representações numéricas, permitindo sua utilização em modelos computacionais. De acordo com MANNING, RAGHAVAN e SCHÜTZE (2008), essas abordagens são fundamentais para a análise de informações textuais em larga escala, sendo amplamente utilizadas em sistemas de recuperação de informação e aprendizado de máquina.

Outro componente relevante na análise de dados é a utilização de técnicas de aprendizado não supervisionado, especialmente algoritmos de agrupamento (*clustering*).

Esses métodos permitem identificar estruturas ocultas nos dados, agrupando elementos com características semelhantes sem a necessidade de rótulos previamente definidos (HAN; KAMBER; PEI, 2012). No contexto deste projeto, o uso de *clustering* pode contribuir para a identificação de padrões entre doenças, medicamentos e avaliações, possibilitando a segmentação de grupos com comportamentos semelhantes.

A qualidade dos agrupamentos gerados por algoritmos de *clustering* deve ser avaliada por meio de métricas adequadas. Nesse contexto, destaca-se o *Silhouette Score*, proposto por ROUSSEEUW (1987), que mede simultaneamente a coesão interna dos grupos e a separação entre clusters distintos. Essa métrica baseia-se na comparação entre a distância média de um elemento em relação aos demais elementos do mesmo grupo e a distância em relação ao grupo mais próximo.

Os valores do *Silhouette Score* variam entre -1 e 1, sendo que valores próximos de 1 indicam agrupamentos bem definidos, valores próximos de zero sugerem sobreposição entre grupos e valores negativos indicam possíveis erros na alocação dos elementos. Conforme discutido por TAN, STEINBACH e KUMAR (2005), essa métrica é amplamente utilizada para validar modelos de agrupamento e auxiliar na determinação do número ideal de clusters.

No contexto deste projeto, a utilização do *Silhouette Score* é fundamental para garantir a qualidade dos agrupamentos utilizados no sistema de recomendação. A identificação de clusters bem definidos permite estruturar recomendações mais consistentes, baseadas em padrões reais observados nos dados, contribuindo para a robustez do modelo proposto.

Além da construção e validação dos modelos, é importante considerar as métricas de avaliação utilizadas em sistemas de recomendação. Indicadores como precisão, recall e erro médio quadrático (RMSE) são amplamente empregados para medir o desempenho dos modelos, permitindo avaliar sua capacidade de prever preferências e gerar recomendações relevantes (HERLOCKER et al., 2004). A escolha adequada dessas métricas é essencial para garantir a confiabilidade dos resultados.

Do ponto de vista social, o desenvolvimento de sistemas baseados em dados na área da saúde está alinhado a iniciativas globais voltadas à melhoria da qualidade de vida da população. Os Objetivos de Desenvolvimento Sustentável propostos pela Organização das Nações Unidas destacam a importância de promover o acesso à saúde e ao bem-estar por meio de soluções inovadoras e acessíveis (ONU, 2015).

Nesse mesmo sentido, a Organização Mundial da Saúde enfatiza a necessidade de promover o uso racional de medicamentos, destacando que decisões informadas são fundamentais para evitar riscos e garantir tratamentos eficazes (OMS, 2002). A utilização de sistemas de recomendação pode contribuir para esse objetivo ao ampliar o acesso à informação de qualidade.

Adicionalmente, questões éticas relacionadas ao uso de dados devem ser consideradas no desenvolvimento de sistemas inteligentes. Aspectos como privacidade, transparência e responsabilidade são fundamentais para garantir a confiança dos usuários. Conforme discutido por FLORIDI et al. (2018), o desenvolvimento de sistemas baseados em inteligência artificial deve seguir princípios éticos que assegurem a proteção dos indivíduos e a utilização responsável das tecnologias.

Dessa forma, a integração entre sistemas de recomendação, técnicas de processamento de linguagem natural, métodos de agrupamento e métricas de validação, como o *Silhouette Score*, constitui uma abordagem robusta e coerente com os objetivos deste projeto. A utilização do dataset UCI ML Drug Review, aliada a essas técnicas, possibilita o desenvolvimento de uma solução capaz de apoiar a tomada de decisão dos usuários, promovendo o acesso à informação e contribuindo para o uso mais consciente de medicamentos.

3. METODOLOGIA

Nesta seção, apresenta-se o delineamento metodológico adotado para o desenvolvimento do sistema de recomendação de medicamentos proposto neste trabalho. A metodologia foi estruturada de forma sistemática, seguindo um fluxo sequencial de etapas que compreendem a definição do problema, coleta e tratamento dos dados, modelagem, avaliação e aplicação do modelo.

A abordagem metodológica fundamenta-se em técnicas de ciência de dados e aprendizado de máquina, com ênfase em métodos de aprendizado não supervisionado. A escolha dessa abordagem deve-se à natureza do problema, que não dispõe de rótulos explícitos de saída, exigindo a identificação de padrões latentes nos dados (HAN; KAMBER; PEI, 2012).

Adicionalmente, a metodologia está alinhada aos princípios dos sistemas de recomendação baseados em dados, os quais buscam reduzir a sobrecarga informacional e apoiar a tomada de decisão por meio da análise de grandes volumes de dados (RICCI; ROKACH; SHAPIRA, 2015).

A Figura 2 apresenta o fluxograma das etapas metodológicas adotadas no projeto.

Figura 2: Fluxo metodológico do projeto

Fonte: Autoral

As subseções a seguir detalham cada uma das etapas.

3.1. DEFINIÇÃO DO PROBLEMA E OBJETIVOS

A definição do problema constitui uma etapa fundamental no desenvolvimento de sistemas baseados em dados, pois orienta todas as decisões metodológicas subsequentes (AGGARWAL, 2016).

No contexto deste trabalho, o problema central consiste na dificuldade enfrentada por usuários na escolha adequada de medicamentos, especialmente em cenários de automedicação. Tal contexto é amplamente discutido pela Organização Mundial da Saúde, que destaca o uso irracional de medicamentos como um dos principais desafios de saúde pública global (OMS, 2002).

Dessa forma, este projeto propõe o desenvolvimento de um sistema de recomendação capaz de sugerir medicamentos com base em dados históricos de avaliações de usuários, considerando critérios como eficácia percebida, frequência de uso e relevância.

O objetivo geral consiste em desenvolver um modelo de recomendação baseado no dataset UCI ML Drug Review, utilizando técnicas de análise de dados e aprendizado não supervisionado.

Como objetivos específicos, destacam-se:

- Estruturar e preparar dados para modelagem;
- Identificar padrões de desempenho entre medicamentos;
- Desenvolver um modelo de agrupamento;
- Implementar uma lógica de recomendação baseada em clusters;
- Avaliar a qualidade dos agrupamentos gerados.

Essa abordagem está alinhada à aplicação de sistemas de recomendação no contexto da saúde, que devem atuar como ferramentas de apoio à decisão, e não como substitutos da atuação profissional (SHICKEL et al., 2017).

3.2. COLETA DE DADOS

Os dados utilizados foram obtidos a partir do *dataset* UCI ML Drug Review, amplamente utilizado em pesquisas acadêmicas e disponibilizado publicamente na plataforma Kaggle.

Esse *dataset* contém mais de 160 mil registros de avaliações de usuários sobre medicamentos, incluindo variáveis estruturadas e não estruturadas. Segundo Drew, Kellogg e Lee (2020), bases de dados provenientes de avaliações reais apresentam elevado valor analítico, pois refletem experiências práticas dos usuários.

As variáveis utilizadas incluem:

- Nome do medicamento;
- Condição tratada;
- Avaliação numérica;
- Número de votos úteis;
- Comentários textuais.

A escolha deste dataset justifica-se por sua riqueza informacional e representatividade, permitindo a construção de modelos baseados em evidências empíricas.

Além disso, a utilização de dados reais está alinhada com práticas contemporâneas de ciência de dados, que priorizam análises baseadas em comportamento observado (MANNING; RAGHAVAN; SCHÜTZE, 2008).

3.3. PRÉ-PROCESSAMENTO E LIMPEZA DOS DADOS

O pré-processamento é uma etapa crítica em projetos de ciência de dados, sendo responsável por garantir a qualidade e a consistência dos dados utilizados (HAN; KAMBER; PEI, 2012).

Inicialmente, foram removidos registros com valores ausentes na variável *condition*, por se tratar de uma variável essencial para o funcionamento do sistema. A presença de dados incompletos pode comprometer a confiabilidade do modelo e introduzir vieses na análise.

Posteriormente, foi realizada uma análise exploratória dos dados (EDA), que tem como objetivo compreender a distribuição das variáveis e identificar padrões relevantes (TAN; STEINBACH; KUMAR, 2005).

A análise da variável *rating* revelou uma distribuição polarizada, característica comum em sistemas de avaliação online, nos quais usuários tendem a avaliar apenas experiências extremamente positivas ou negativas.

Além disso, foram analisadas as frequências das condições e a distribuição dos medicamentos, permitindo identificar padrões de uso e relevância.

3.4. DIVISÃO E ESTRUTURAÇÃO DOS DADOS

Como o problema abordado utiliza aprendizado não supervisionado, não há necessidade de divisão tradicional em conjuntos de treino e teste.

Em vez disso, foi realizada uma transformação estrutural dos dados por meio de agregação, convertendo o dataset em uma representação centrada nos medicamentos.

Essa etapa é conhecida como feature engineering, sendo fundamental para melhorar a qualidade dos modelos (AGGARWAL, 2016).

Foram criadas as seguintes variáveis:

- Média das avaliações (indicador de qualidade percebida);
- Média de utilidade (indicador de relevância social);
- Número de condições tratadas (indicador de abrangência).

Essa abordagem permite representar cada medicamento como um vetor numérico, possibilitando a aplicação de algoritmos de agrupamento.

3.5. SELEÇÃO E IMPLEMENTAÇÃO DO ALGORITMO

O algoritmo escolhido foi o K-Means, um dos métodos mais utilizados em aprendizado não supervisionado para tarefas de agrupamento.

Segundo Han, Kamber e Pei (2012), o K-Means é adequado para identificar grupos homogêneos em dados numéricos, sendo eficiente e escalável para grandes volumes de dados.

A escolha do K-Means também se justifica pela natureza do problema, que busca identificar perfis de desempenho entre medicamentos.

Antes da aplicação do algoritmo, foi realizada a padronização dos dados utilizando o StandardScaler, técnica que transforma as variáveis para uma mesma escala.

Essa etapa é essencial, pois o K-Means utiliza distância euclidiana como métrica de similaridade, sendo sensível à magnitude das variáveis (TAN; STEINBACH; KUMAR, 2005).

3.6. SELEÇÃO E IMPLEMENTAÇÃO DO ALGORITMO

O treinamento do modelo foi realizado por meio da aplicação do algoritmo K-Means sobre os dados previamente tratados e padronizados. Como o K-Means requer a definição prévia do número de clusters (K), tornou-se necessário empregar uma técnica adequada para determinar esse parâmetro de forma fundamentada.

Para isso, foi utilizado o Método do Cotovelo (Elbow Method), uma abordagem amplamente adotada na literatura para identificação do número ideal de agrupamentos (HAN; KAMBER; PEI, 2012).

O método baseia-se na análise da inércia, também conhecida como *Within-Cluster Sum of Squares (WCSS)*, que mede a soma das distâncias quadráticas entre cada ponto de dados e o centróide do cluster ao qual pertence. De forma geral, a inércia pode ser definida como:

$$WCSS = \sum_{i=1}^{k} \sum_{x \epsilon C_i} ||x - \mu_i||^2$$

- k representa o número de clusters;
- C_i corresponde ao conjunto de pontos pertencentes ao cluster iii;
- x representa cada ponto de dados;

- μ_i é o centróide do cluster iii.

À medida que o número de clusters aumenta, a inércia tende a diminuir, uma vez que os grupos se tornam mais específicos e compactos. No entanto, essa redução não ocorre de maneira linear. Inicialmente, há uma queda acentuada na inércia, seguida por uma redução mais suave.

O "cotovelo" do gráfico — ponto em que a taxa de redução da inércia começa a diminuir significativamente — indica o número ideal de clusters, equilibrando a complexidade do modelo e a qualidade do agrupamento.

No presente estudo, a análise do gráfico evidenciou que esse ponto ocorre em K = 4, indicando que esse número de clusters proporciona uma segmentação adequada dos medicamentos sem introduzir complexidade desnecessária ao modelo.

Com base nessa definição, o algoritmo K-Means foi treinado com quatro clusters, permitindo a identificação de diferentes perfis de desempenho entre os medicamentos analisados.

3.7. AVALIAÇÃO DO DESEMPENHO

A avaliação do modelo de agrupamento foi realizada por meio do Silhouette Score, uma métrica amplamente utilizada para validar a qualidade de clusters em problemas de aprendizado não supervisionado (ROUSSEEUW, 1987).

Diferentemente da inércia, que avalia apenas a coesão interna dos clusters, o Silhouette Score considera simultaneamente dois aspectos fundamentais:

- Coesão: quão próximos estão os pontos dentro do mesmo cluster;
- Separação: quão distantes estão os clusters entre si.

Para cada ponto iii, o coeficiente de silhueta é definido como:

$$s(i) = \frac{b(i) - a(i)}{max(a(i), b(i))}$$

onde:

- $a(i)$: distância média entre o ponto iii e os demais pontos do mesmo cluster;
- $b(i)$: menor distância média entre o ponto iii e os pontos de outro cluster mais próximo.

O valor de $s(i)$ varia entre -1 e 1:

- valores próximos de 1 indicam que o ponto está bem alocado;
- valores próximos de 0 indicam sobreposição entre clusters;
- valores negativos indicam possível classificação incorreta.

O modelo desenvolvido apresentou um Silhouette Score médio de aproximadamente 0,407, indicando que os clusters são razoavelmente bem definidos, embora exista certa sobreposição entre alguns grupos.

Esse resultado é considerado aceitável para dados reais e heterogêneos, especialmente no contexto de avaliações subjetivas de usuários, como é o caso deste dataset (TAN; STEINBACH; KUMAR, 2005).

Além da avaliação quantitativa, foi realizada uma análise visual por meio da técnica de Análise de Componentes Principais (PCA), que permite reduzir a dimensionalidade dos dados e projetá-los em um espaço bidimensional.

Essa visualização possibilitou observar a separação dos clusters e identificar padrões estruturais, complementando a interpretação do Silhouette Score.

3.8. OTIMIZAÇÃO E AJUSTES

Após a avaliação inicial do modelo, foram implementadas melhorias com o objetivo de aumentar a relevância e a robustez das recomendações geradas.

Uma das principais estratégias adotadas foi a identificação do chamado "cluster premium", definido como aquele que apresenta a maior média de avaliação (*avg_rating*). Essa abordagem baseia-se na premissa de que medicamentos com avaliações consistentemente altas tendem a representar melhores opções sob a perspectiva dos usuários.

A lógica de recomendação foi então estruturada da seguinte forma:

1. Identificação do cluster com maior média de avaliação;
2. Filtragem dos medicamentos associados à condição informada;
3. Seleção dos medicamentos pertencentes ao cluster premium;
4. Ordenação com base em utilidade (*usefulCount*) e avaliação;
5. Retorno das melhores recomendações.

Adicionalmente, foi implementada uma estratégia de fallback, que consiste em retornar os melhores medicamentos disponíveis independentemente do cluster, caso não existam itens do cluster premium para determinada condição.

Essa abordagem garante que o sistema mantenha sua funcionalidade mesmo em cenários com baixa representatividade de dados, aumentando sua aplicabilidade prática. Segundo Ricci, Rokach e Shapira (2015), a adoção de estratégias híbridas e mecanismos de fallback é essencial para melhorar a robustez dos sistemas de recomendação.

3.9. IMPLANTAÇÃO E MONITORAMENTO

A etapa final do processo metodológico consiste na aplicação prática do modelo desenvolvido, possibilitando sua utilização como ferramenta de apoio à decisão.

O sistema de recomendação foi projetado para operar de forma dinâmica, recebendo como entrada a condição clínica informada pelo usuário e retornando uma lista ordenada de medicamentos recomendados.

O fluxo de funcionamento do sistema pode ser descrito em cinco etapas principais:

1. Identificação da condição clínica;
2. Filtragem dos medicamentos associados;
3. Classificação com base nos clusters gerados;
4. Priorização dos medicamentos de maior desempenho;
5. Geração da lista final de recomendações.

Do ponto de vista operacional, o modelo pode ser integrado a diferentes plataformas, como aplicações web, dashboards analíticos ou sistemas de apoio farmacêutico.

Entretanto, conforme destacado por Goodfellow, Bengio e Courville (2016), modelos de aprendizado de máquina não devem ser considerados estáticos. Dessa forma, recomenda-se a implementação de um processo contínuo de monitoramento, que inclua:

- atualização periódica da base de dados;
- reavaliação do número de clusters;
- análise de desempenho ao longo do tempo;
- ajustes na lógica de recomendação.

Esse processo é fundamental para garantir a adaptabilidade do sistema a mudanças nos dados e preservar a qualidade das recomendações.

CONCLUSÃO

REFERÊNCIAS

AGGARWAL, Charu C. *Recommender Systems: The Textbook*. Cham: Springer, 2016.

BURKE, Robin. Hybrid recommender systems: Survey and experiments. *User Modeling and User-Adapted Interaction*, v. 12, n. 4, p. 331–370, 2002.

DREW, Daniel A.; KELLOGG, Megan D.; LEE, Hyun J. Machine learning in medicine: A practical introduction. *New England Journal of Medicine*, 2020.

FLORIDI, Luciano et al. AI4People—An ethical framework for a good AI society. *Minds and Machines*, v. 28, p. 689–707, 2018.

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. *Deep Learning*. Cambridge: MIT Press, 2016.

HAN, Jiawei; KAMBER, Micheline; PEI, Jian. *Data Mining: Concepts and Techniques*. 3. ed. Waltham: Morgan Kaufmann, 2012.

HARPER, F. Maxwell; KONSTAN, Joseph A. The MovieLens datasets: History and context. *ACM Transactions on Interactive Intelligent Systems*, v. 5, n. 4, 2016.

HERLOCKER, Jonathan L. et al. Evaluating collaborative filtering recommender systems. *ACM Transactions on Information Systems*, v. 22, n. 1, 2004.

JESSICA LI. KUC Hackathon Winter 2018 – Drug Review Dataset. Kaggle, 2018.

JOLLIFFE, Ian T. *Principal Component Analysis*. 2. ed. New York: Springer, 2002.

MANNING, Christopher D.; RAGHAVAN, Prabhakar; SCHÜTZE, Hinrich. *Introduction to Information Retrieval*. Cambridge: Cambridge University Press, 2008.

MINER, Gary et al. *Practical Text Mining and Statistical Analysis for Non-structured Text Data Applications*. Academic Press, 2012.

ORGANIZAÇÃO DAS NAÇÕES UNIDAS (ONU). *Transformando nosso mundo: a Agenda 2030 para o Desenvolvimento Sustentável*. Nova York: ONU, 2015.

ORGANIZAÇÃO MUNDIAL DA SAÚDE (OMS). *Promoting rational use of medicines: core components*. Geneva: WHO, 2002.

RICCI, Francesco; ROKACH, Lior; SHAPIRA, Bracha. *Recommender Systems Handbook*. 2. ed. Boston: Springer, 2015.

ROUSSEEUW, Peter J. Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, v. 20, p. 53–65, 1987.

SARWAR, Badrul et al. Item-based collaborative filtering recommendation algorithms. In: *Proceedings of the 10th International World Wide Web Conference*. 2001.

SHICKEL, Benjamin et al. Deep learning in healthcare: A review. *Journal of Biomedical Informatics*, v. 75, p. 3–21, 2017.

TAN, Pang-Ning; STEINBACH, Michael; KUMAR, Vipin. *Introduction to Data Mining*. Boston: Pearson, 2005.